SCOUTING DE FUTBOLISTAS MEDIANTE ANÁLISIS DE DATOS:

Identificación de perfiles para mediocentro organizador sustituto de Toni Kroos

Autor: [Yeray Martínez Acha]

Fecha: [Marzo, 2026]

Índice

1. Contexto 3
1.1 Scouting Mediocentro 3
2. Objetivo del proyecto 3
3. Descripción del Data Set 3
4. Exploratory Data Analysis del medio centro sustituto de Toni Kroos 5
4.1 Histogramas de las variables 5
4.2 Boxplots 6
4.3 Matriz de correlaciones 9
4.4 Variables filtro 9
5. Análisis del sustituto de Toni Kroos – Distancia euclidea 11
5.1 Principal Component Analysis (PCA) 11
5.2 Gráficos Radar 13
6. Conclusiones 16
6.1 Limitaciones del modelo 16
6.2 Conclusión final 17

1. Contexto

En este proyecto se simula el trabajo del departamento de scouting del Real Madrid CF, con el objetivo de identificar un posible candidato a una posición relevante para el equipo: mediocampista. El principal problema radica que desde que Toni Kroos se retiró del club, el Real Madrid no ha podido encontrar un recambio interno para el futbolista alemán. El análisis se basa en datos estadísticos de jugadores de las cinco grandes ligas europeas durante la temporada 2024/2025, incluyendo métricas relacionadas con producción ofensiva, generación de ocasiones y progresión del balón

1.1 Scouting Mediocentro

El primer objetivo es identificar jugadores con características similares a Toni Kroos, histórico mediocampista del club que se retiró el año pasado. Por lo que se busca un relevo joven y con capacidad de impactar en el juego Kroos se ha caracterizado por su capacidad para:

- organizar el juego del equipo
- progresar el balón hacia zonas ofensivas
- generar oportunidades de gol.

Por ello, el análisis se centra en métricas relacionadas con la creación y progresión del juego, como pases progresivos, asistencias esperadas y contribución ofensiva. A partir de estas variables se realiza un análisis de similitud para identificar

2. Objetivo del proyecto

Demostrar cómo el análisis de datos puede utilizarse para apoyar el proceso de scouting, permitiendo:

- identificar perfiles de jugadores específicos
- reducir el número de candidatos potenciales
- apoyar la toma de decisiones en el mercado de fichajes.

3. Descripción del Data Set

El dataset muestra las estadísticas de todos los jugadores de las 5 grandes de ligas a través de las siguientes variables:

- Player: The name of the player.
- Nation: The player's nationality.
- Pos: The player's position (e.g., forward, midfielder, defender).
- Age: The player's age.
- MP (matches played): Total matches played number
- Starts: Number of matches the player started.
- Min (Minutes): Total minutes played by the player (this might be the same as MP).

- 90s (90s Played): The equivalent of 90-minute matches played by the player (e.g., 1.5 = 135 minutes).
- Gls (Goals): Total number of goals scored by the player.
- Ast (Assists): Total number of assists made by the player.
- G+A (Goals + Assists): Total number of goals and assists combined.
- G-PK (Goals - Penalty Kicks): Total number of goals scored excluding penalty kicks.
- PK (Penalty Kicks): Number of penalty goals scored by the player.
- PKatt (Penalty Kicks Attempted): Number of penalty kicks attempted by the player.
- CrdY (Yellow Cards): Number of yellow cards received by the player.
- CrdR (Red Cards): Number of red cards received by the player.
- xG (Expected Goals): The expected number of goals from the player's shots.
- npxG (Non-Penalty Expected Goals): Expected goals excluding penalties.
- xAG (Expected Assists): The expected number of assists from the player's passes.
- npxG+xAG (Non-Penalty xG + xAG): Total of non-penalty expected goals and expected assists.
- PrgC (Progressive Carries): Number of times the player carried the ball forward.
- PrgP (Progressive Passes): Number of passes made by the player that moved the ball forward.
- PrgR (Progressive Runs): Number of times the player made runs forward with the ball.
- Gls (Goals): (Repeated, already defined) Total number of goals scored.
- Ast (Assists): (Repeated, already defined) Total number of assists made.
- G+A (Goals + Assists): (Repeated, already defined) Total number of goals and assists combined.
- G-PK (Goals - Penalty Kicks): (Repeated, already defined) Goals scored excluding penalty kicks.
- G+A-PK (Goals + Assists - Penalty Kicks): Total goals and assists minus penalty goals.
- xG (Expected Goals): (Repeated, already defined) Expected number of goals from the player's shots.
- xAG (Expected Assists): (Repeated, already defined) Expected number of assists from the player's passes.
- xG+xAG (Expected Goals + Expected Assists): Total expected goals and assists.
- npxG (Non-Penalty Expected Goals): (Repeated, already defined) Expected goals excluding penalties.

- npxG+xAG (Non-Penalty xG + Expected Assists): Total of non-penalty expected goals and expected assists.

4. Exploratory Data Analysis del medio centro sustituto de Toni Kroos

Como el club ha pedido específicamente un recambio de Toni Kroos, cuya función era ser el mediocampista organizador y creador de juego, nos centraremos en aquellas variables, las cuales tengan relación con el perfil.

Las cuales son:

- Ast (Assists): Total number of assists made by the player.
- xAG (Expected Assists): The expected number of assists from the player's passes.
- PrgP (Progressive Passes): Number of passes made by the player that moved the ball forward.
- xAG (Expected Assists): (Repeated, already defined) Expected number of assists from the player's passes.
- PrgC (Progressive Carries): Number of times the player carried the ball forward.
- AS_90(Assists per 90 minutes): Number of assists per 90 minutes
- XAG_90(Expected assists per 90 minutes): Number of assists expected per 90 minutes player

4.1 Histogramas de las variables

Distribución xAG: Asistencias Esperadas

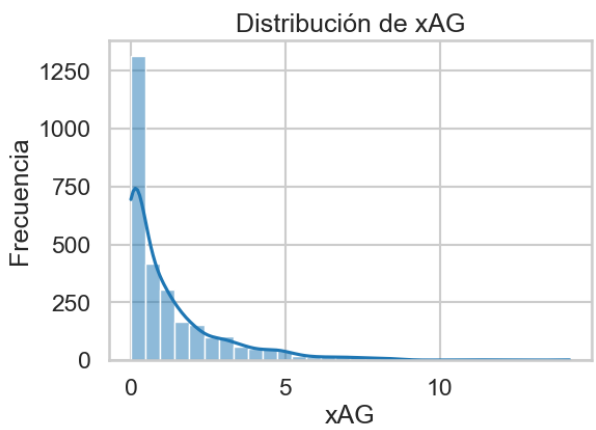

Distribución Ast: Asistencias en la temporada

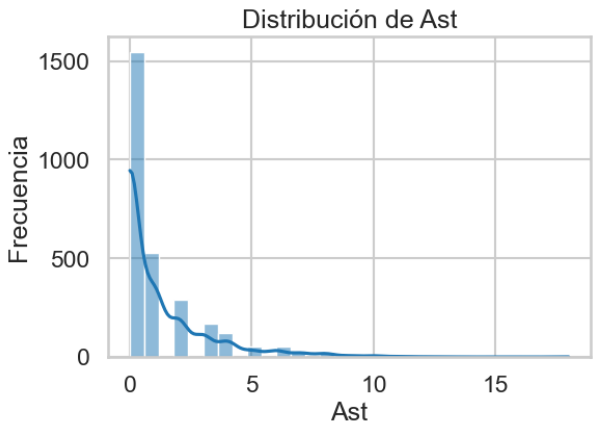

Distribución PrgP: Pases progresivos

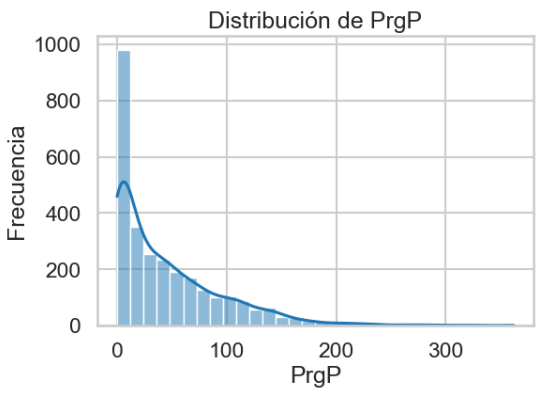

Distribución Prgc: Carreras progresivas

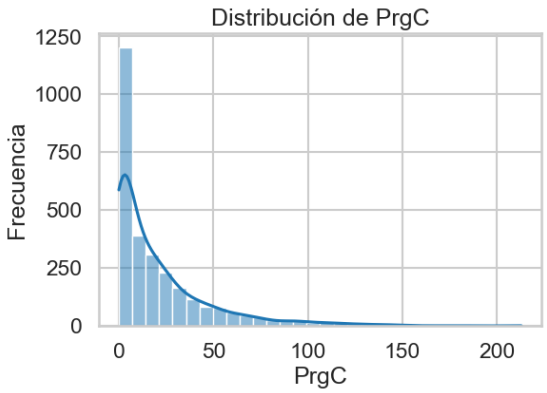

Distribución Ast_90: Asistencias por 90 minutos

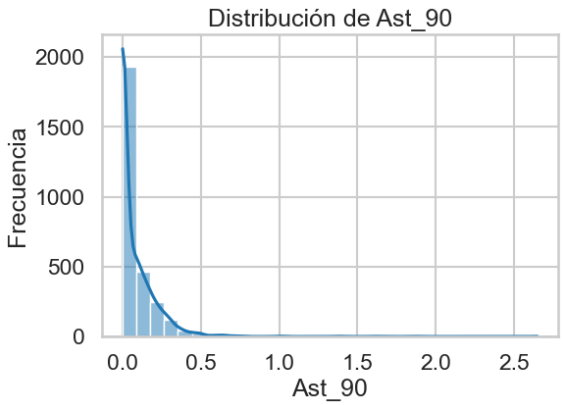

Distribución xAG_90: Asistencias esperadas por 90 minutos

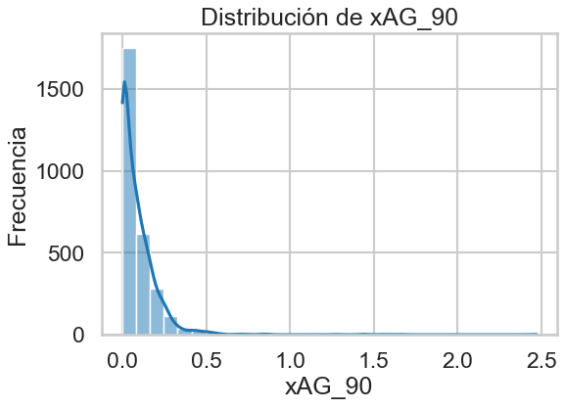

La distribución de varias métricas ofensivas presenta un sesgo positivo (o sesgo a la derecha) considerable. La mayoría de los jugadores muestran valores relativamente bajos, mientras que un pequeño grupo exhibe contribuciones significativamente más altas. Este patrón es esperado en los conjuntos de datos de fútbol, ya que la producción ofensiva se concentra en un grupo más reducido de jugadores.

4.2 Boxplots

Asistencias por posición

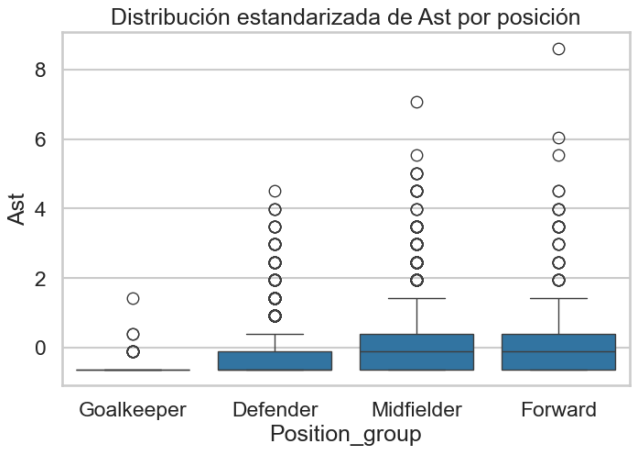

Asistencias esperadas por posición

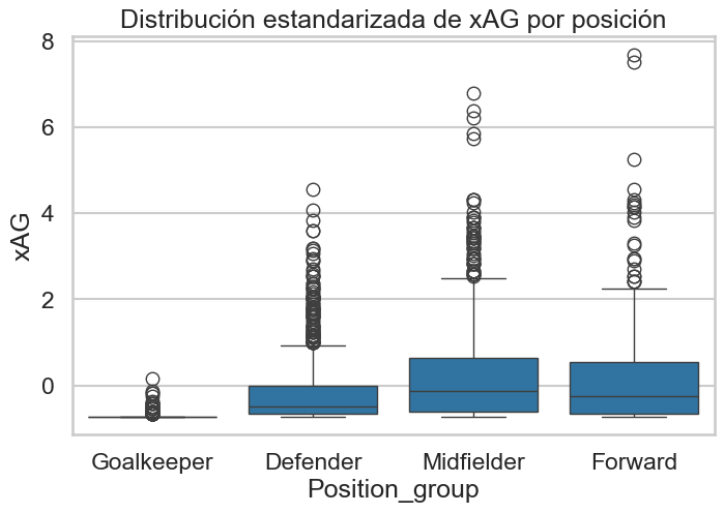

Pases progresivos por posición

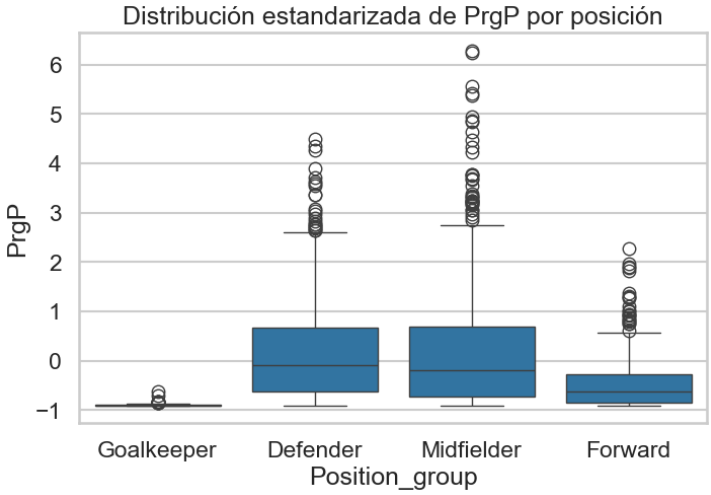

Carreras progresivas por posición

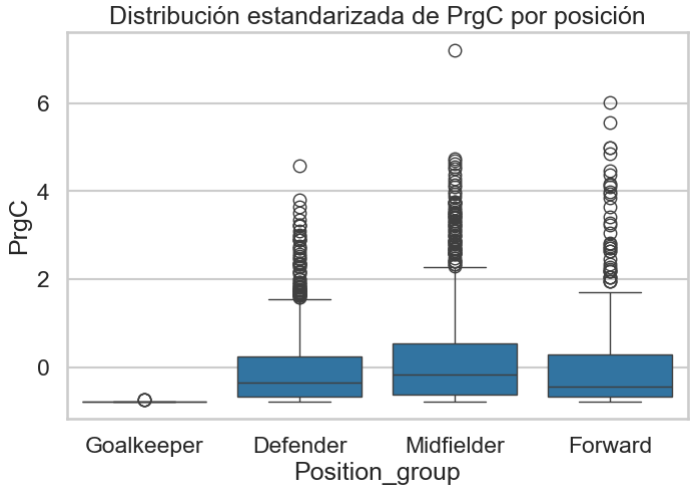

Asistencias por 90 minutos por posición

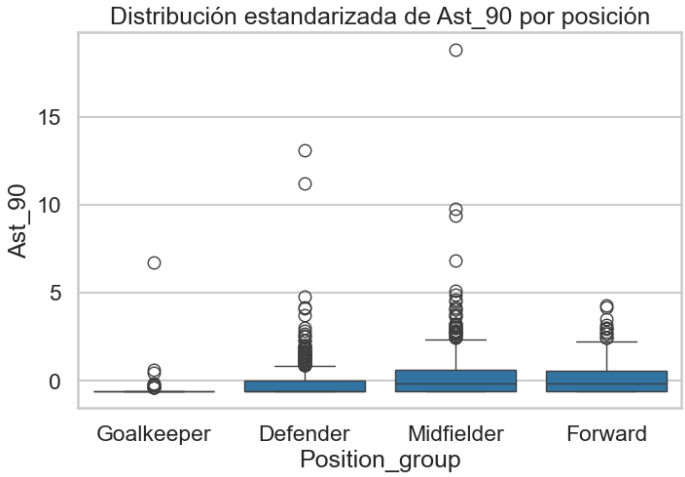

Asistencias esperadas por 90 minutos según posición

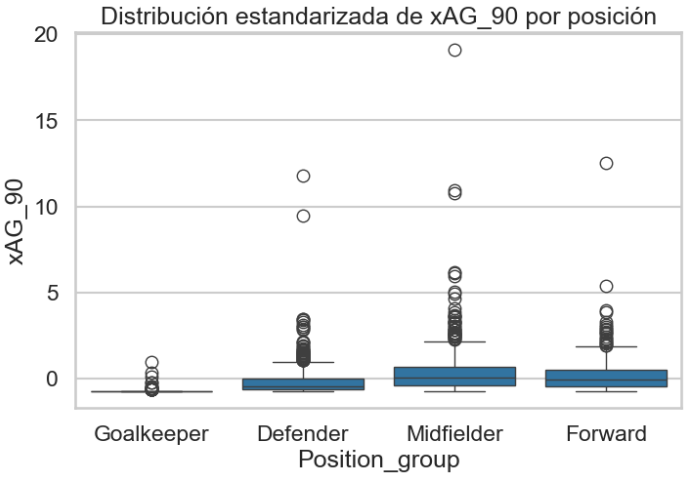

Como se puede apreciar, en general, se observa que los mediocampistas presentan valores más elevados y una mayor dispersión en variables relacionadas con la progresión del balón y la creación de juego, especialmente en xAG, PrgP y PrgR.

En comparación con otras posiciones, los mediocampistas muestran una presencia más consistente en estos indicadores, lo que confirma que estas variables capturan aspectos relevantes del juego en esta posición

4.3 Matriz de correlaciones

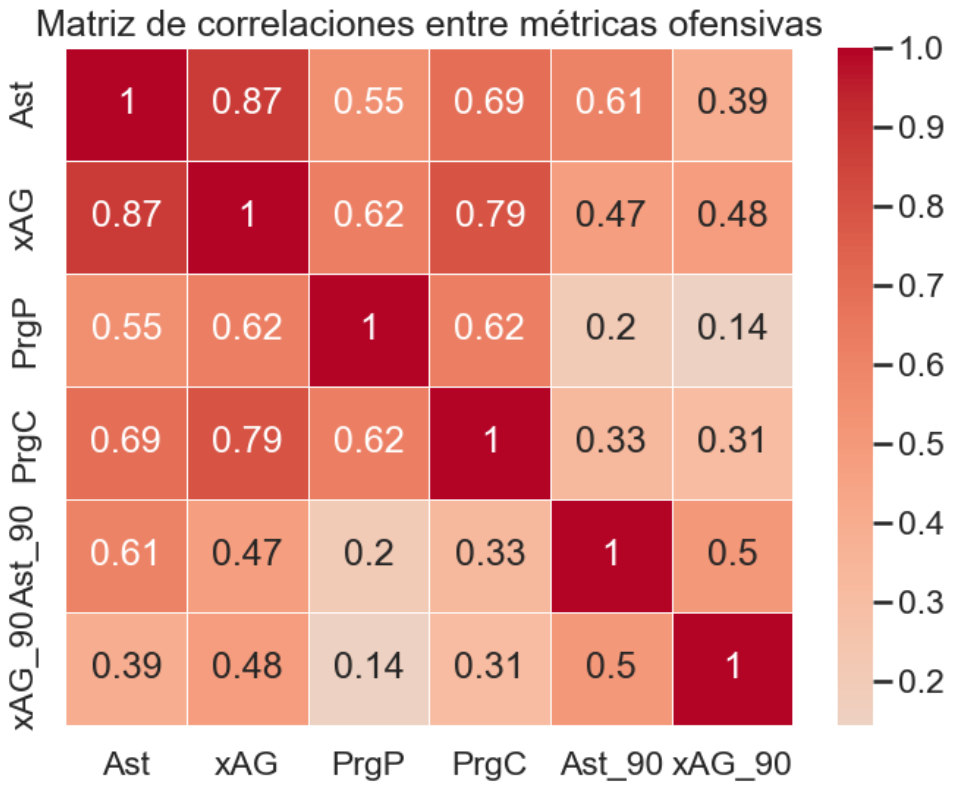

El mapa de correlación muestra relaciones positivas moderadas fuertes entre casi todas las variables analizadas, lo que indica que estas métricas están relacionadas con diferentes aspectos de la contribución ofensiva de los jugadores. Un aspecto relevante del mapa es que las correlaciones no son perfectamente altas entre todas las variables, lo que indica que cada métrica captura dimensiones ligeramente distintas del juego ofensivo (progresión, creación o contribución ofensiva). Esto es importante para el análisis, ya que evita redundancias y permite que cada variable aporte información complementaria

4.4 Variables filtro

Desde el club se ha exigido un recambio por un futbolista joven y que su impacto sea inmediato, por lo que debe tener experiencia. Por lo que las variables Age, la cual determina la edad del jugador, Min (Minutes), es decir la cantidad de minutos que el jugador jugó la temporada pasa y 90s, es decir, la cantidad de partidos que el jugador jugó la temporada pasada, tendrán relevancia a la hora de hacer el filtrado.

Como futbolista joven se exige que la edad sea menor que la media. Para filtrar el resto de las variables, se hará un boxplot para determinar la mediana de cada variable, y el filtrado irá en función de que los minutos y partidos jugados estén por encima de esa mediana.

Para ello, se filtra por posición con el nodo "Row Filter" y nos quedaremos solo con aquellos futbolistas que sean mediocampistas

Mediana de Age: 24.0

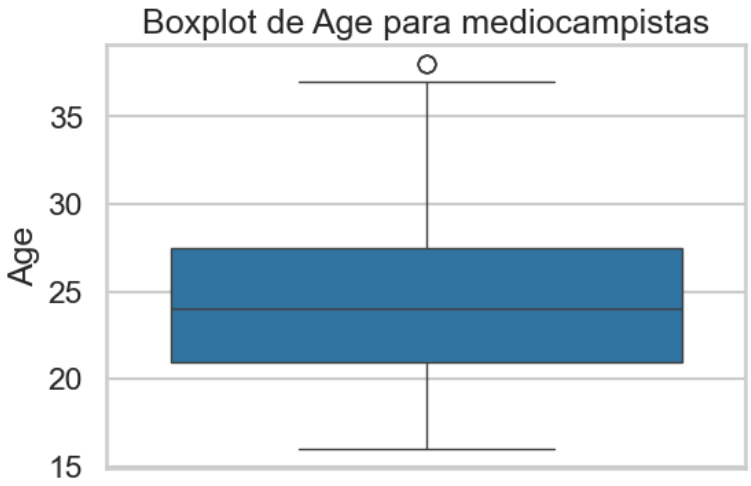

Mediana de Min: 1013.0

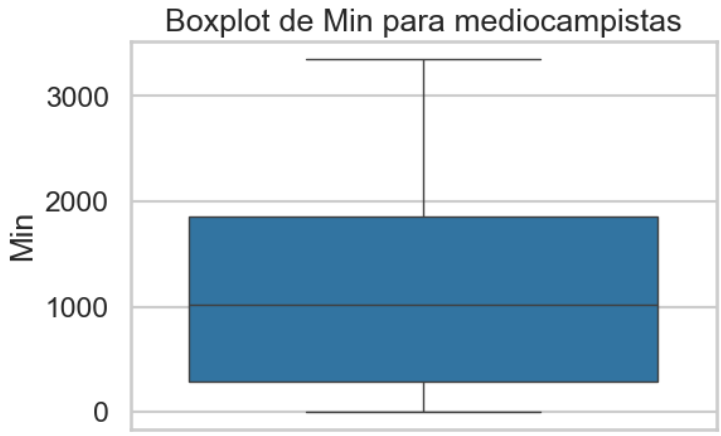

Mediana de 90s: 11.3

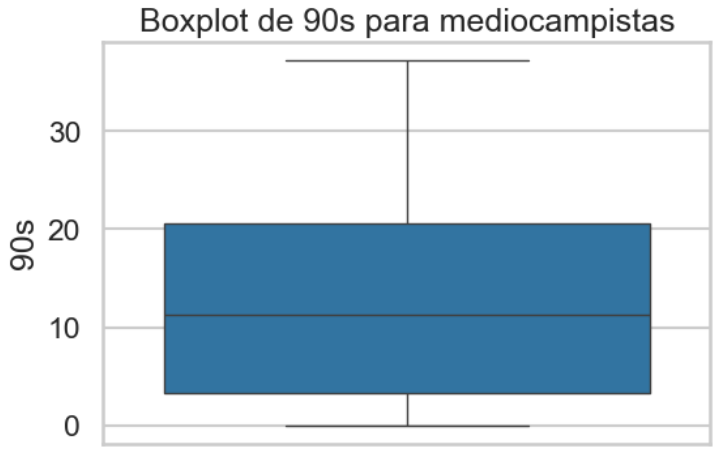

5. Análisis del sustituto de Toni Kroos – Distancia euclidea

El modelo consiste en un análisis de similitud entre jugadores basado en distancias en un espacio multidimensional de variables de rendimiento, cuyo objetivo es identificar mediocampistas con características comparables al estilo de juego de Toni Kroos.

El objetivo del modelo es identificar jugadores que presenten un perfil estadístico similar al de Kroos a partir de un conjunto de métricas relacionadas con la creación de juego y la progresión del balón. Una vez preparados los datos, se calcula la distancia entre jugadores en el espacio de variables utilizando la distancia euclidiana.

Cada jugador se representa como un punto en un espacio multidimensional definido por las variables seleccionadas. Finalmente, se comparan las distancias entre todos los jugadores y el perfil de Kroos, identificando aquellos con menor distancia estadística, es decir, aquellos cuyo perfil de juego es más similar.

Para el análisis se pedirán aquellos 20 futbolistas más similares a Toni Kroos.

Row_number	Player	Team	Age	Distance_to_Kroos
220	Angelo Stiller	Stuttgart	23.0	1,358222
87	Enzo Fernández	Chelsea	23.0	2,348969
187	Nicolás Paz	Como	19.0	3,012396
175	João Neves	Paris S-G	19.0	3,031887
44	Lamine Camara	Monaco	20.0	3,086301
188	Pedri	Barcelona	21.0	3,248764
127	Lee Kang-in	Paris S-G	23.0	3,314489
7	Elliot Anderson	Nott'ham Forest	21.0	3,652478
214	Xavi Simons	RB Leipzig	21.0	3,703308
64	arles De Ketelaere	Atalanta	23.0	3,888401

5.1 Principal Component Analysis (PCA)

Para visualizar la similitud entre Toni Kroos y los jugadores identificados mediante el modelo de distancia, se aplicó un análisis de Principal Component Analysis (PCA). Esta técnica reduce el espacio multidimensional de variables a dos componentes principales, permitiendo representar gráficamente a los jugadores. En el gráfico, los jugadores más cercanos a Kroos presentan perfiles estadísticos más similares en términos de creación de juego y progresión del balón.

Un aspecto relevante que se podrá observar es que algunos jugadores que parecen visualmente cercanos a Kroos en el gráfico pueden tener una distancia mayor en el modelo. Esto ocurre porque el gráfico representa únicamente dos dimensiones del conjunto completo de variables analizadas. En otras palabras, el plano visual simplifica la información original para poder representarla de forma comprensible, pero el cálculo de similitud se realiza teniendo en cuenta todas las métricas simultáneamente. Por ello, dos jugadores pueden parecer próximos en el gráfico, pero diferir en otras características que no se reflejan directamente en la visualización.

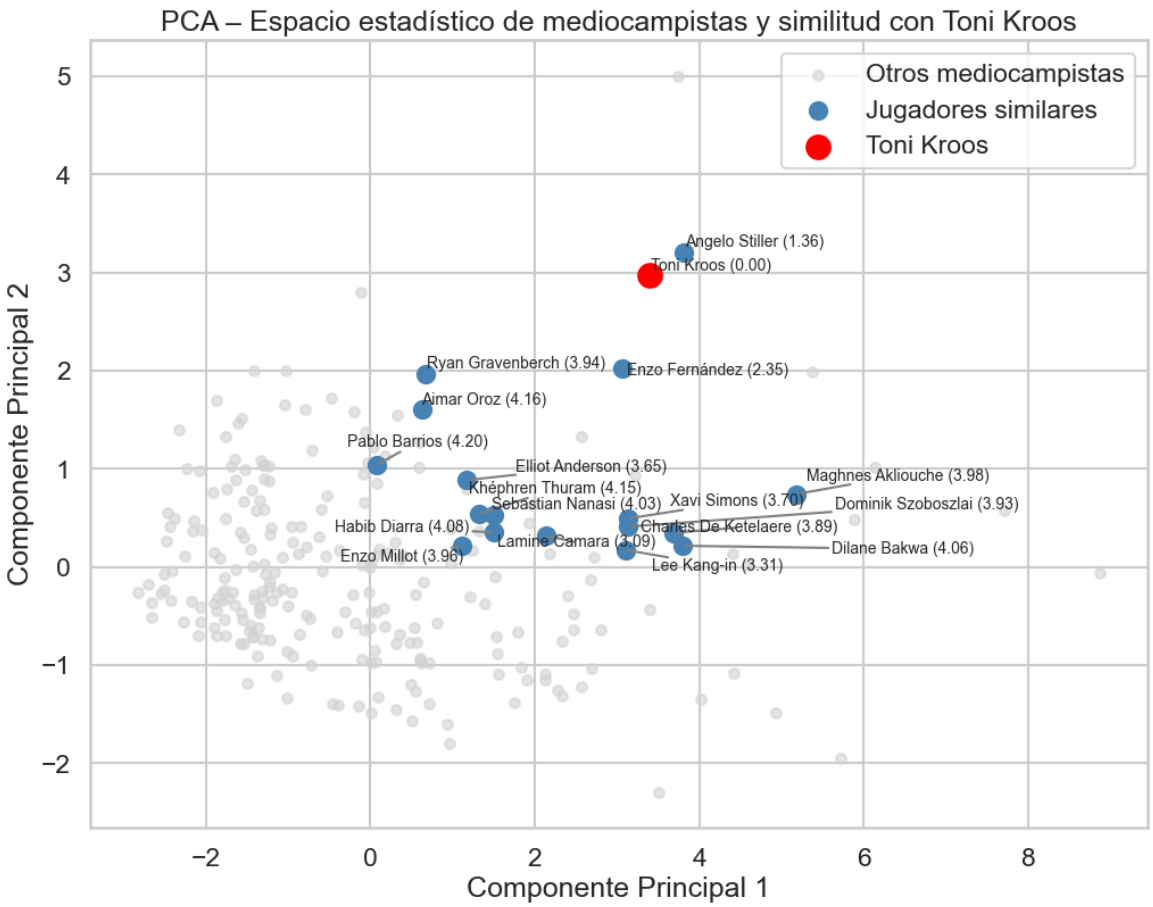

El gráfico representa el espacio estadístico en el que se comparan los mediocampistas a partir de las variables relacionadas con la creación de juego y la progresión del balón. En él aparecen todos los mediocampistas del conjunto de datos filtrado en color gris, mientras que los jugadores identificados como candidatos más similares al perfil de Toni Kroos se destacan en azul. El propio Kroos aparece marcado en rojo como punto de referencia.

Uno de los jugadores que aparece más cercano al perfil de Kroos es Angelo Stiller. Su posición en el gráfico se sitúa muy próxima al punto que representa al mediocampista alemán, lo que sugiere que comparte patrones similares en las métricas analizadas. Este resultado es coherente con el valor de distancia obtenido en el modelo, que lo identifica como el jugador más cercano al perfil de Kroos dentro del conjunto de candidatos.

En el caso de Enzo Fernández también se observa una proximidad relativamente clara con respecto a Kroos, aunque algo mayor que en el caso de Stiller. Esto indica que, aunque comparte varias características en términos de creación de juego, presenta algunas diferencias en otras dimensiones de las métricas analizadas.

En conjunto, el gráfico permite confirmar visualmente los resultados obtenidos en el modelo de distancia. Los jugadores seleccionados por el algoritmo tienden a concentrarse en una región del espacio estadístico cercana al perfil de Toni Kroos, lo que refuerza la validez del proceso utilizado para identificar posibles sustitutos o perfiles similares dentro del mercado de mediocampistas. Entre ellos, Angelo Stiller y Enzo Fernández destacan como los perfiles que presentan mayor similitud con el mediocampista alemán en las variables analizadas.

5.2 Gráficos Radar

Para complementar el análisis de similitud, se utilizaron gráficos radar que comparan el perfil estadístico de Toni Kroos con el de los jugadores identificados como candidatos por el modelo de distancia. Cada eje representa una de las variables utilizadas en el modelo, lo que permite observar de forma intuitiva las similitudes y diferencias en términos de creación de juego y progresión del balón.

5.2.1 Comparación Toni Kroos vs Angelo Stiller

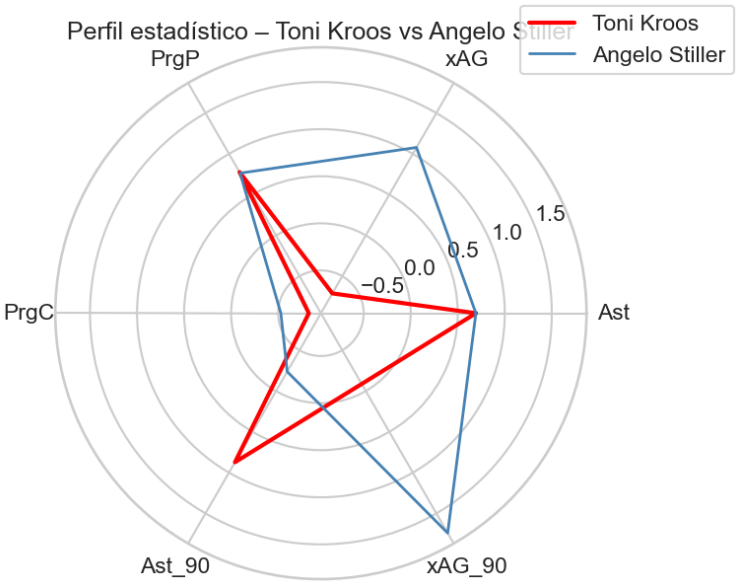

5.2.2 Comparación Toni Kroos vs Enzo Fernández

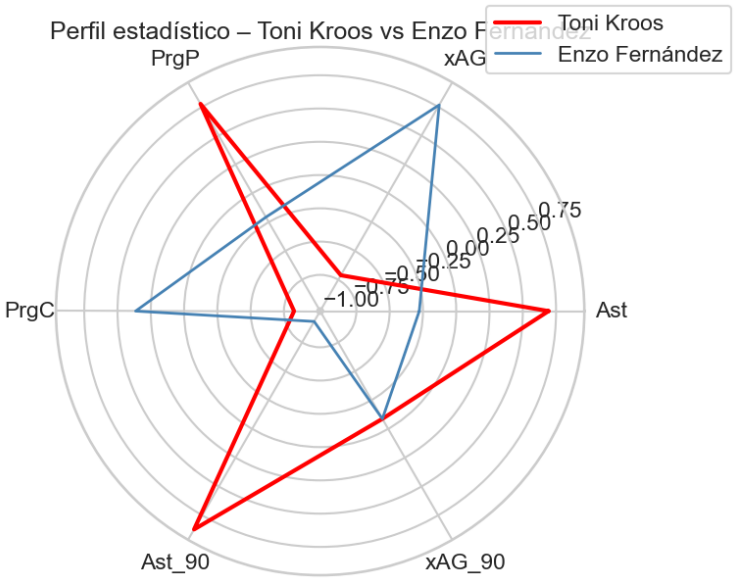

5.2.3 Comparación Toni Kroos vs Nico Paz

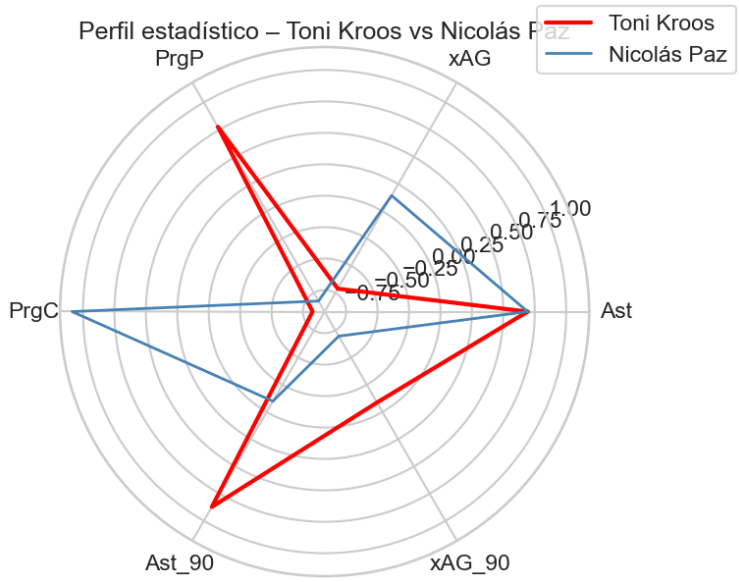

5.2.4 Comparación Toni Kroos vs Joao Neves

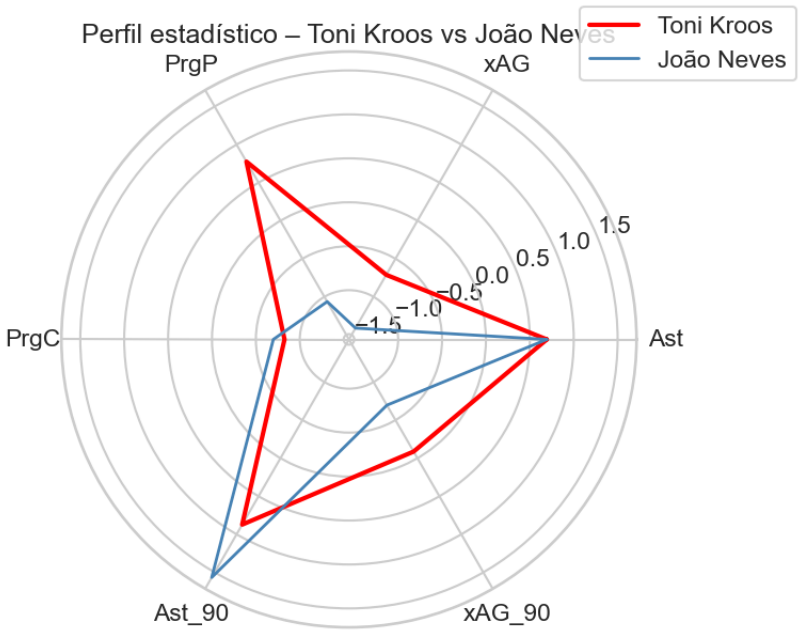

5.2.5 Comparación Toni Kroos vs Lamine Kamara

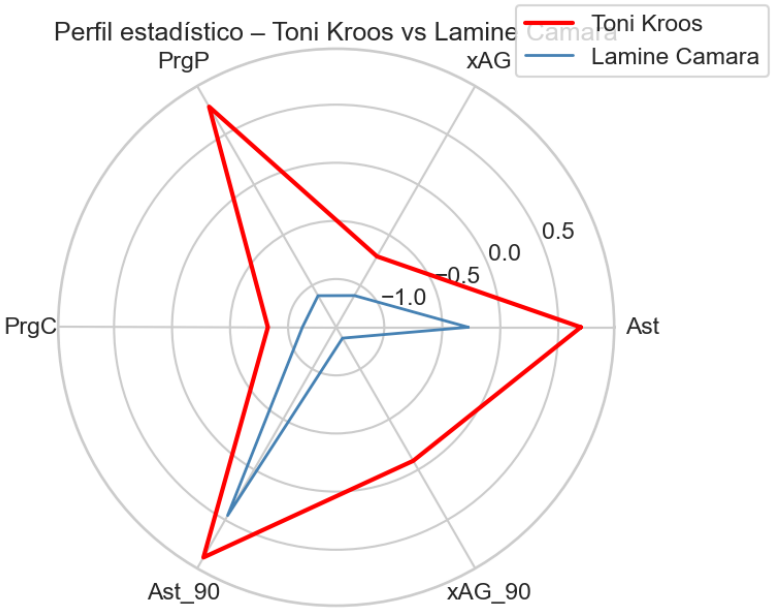

5.2.6 Comparación Toni Kroos vs Pedri

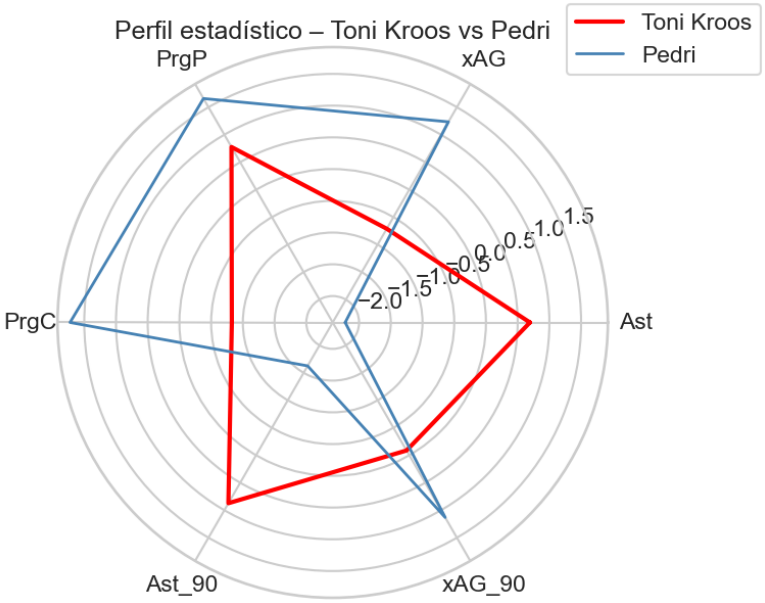

El análisis identifica distintos grados de similitud con el perfil de Toni Kroos en creatividad, progresión y eficiencia.

Angelo Stiller es el jugador más cercano, con una estructura estadística similar y alta capacidad creativa (xAG), propia de un mediocentro organizador.

Enzo Fernández presenta un perfil más dinámico, con mayor conducción y generación, aunque menos eficiente que Kroos.

Nicolás Paz se aleja claramente, con un perfil ofensivo y orientado a la conducción, más propio de un mediapunta.

João Neves muestra equilibrio y eficiencia en asistencias, pero menor impacto en creatividad y progresión.

Lamine Camara es el perfil más distante, con menor influencia general en el juego ofensivo.

Pedri destaca en progresión y creatividad, aunque con un estilo más ofensivo y menos posicional.

6. Conclusiones

El análisis combinado de distancias euclidianas y visualización mediante PCA y radar charts permite identificar perfiles de mediocampistas con similitudes al estilo de Toni Kroos, principalmente en términos de creación de juego y progresión del balón.

Entre los jugadores analizados, Angelo Stiller emerge como el perfil más cercano, mostrando una estructura estadística muy similar en las variables clave del modelo. Otros jugadores como Enzo Fernández o João Neves presentan similitudes parciales, aunque con diferencias en el estilo de juego, tendiendo hacia perfiles más dinámicos o verticales. Sin embargo, la lista de 20 futbolistas servirá para filtrar al director deportivo futbolistas con cierto parecido a Kroos, y luego se deberá decidir cual encaja de manera óptima en el equipo. Además de un segundo informe, donde se incluirán otro tipo de variables, como, por ejemplo, precio del futbolista, salario, proyección etc.

El uso del PCA ha permitido validar visualmente estos resultados, mostrando que los jugadores seleccionados se agrupan en una zona cercana al perfil de Kroos dentro del espacio estadístico. Por su parte, los radar charts han facilitado la interpretación individual, permitiendo identificar en qué variables concretas se producen las similitudes y diferencias.

6.1 Limitaciones del modelo

A pesar de la coherencia de los resultados, es importante destacar una limitación clave del análisis:

La base de datos utilizada está centrada principalmente en métricas ofensivas y de progresión, lo que implica que no recoge de forma completa todas las dimensiones del juego de un futbolista.

En particular, en el caso de un mediocentro:

- gran parte de su valor se encuentra en aspectos defensivos
- como recuperaciones, posicionamiento, presión o lectura del juego

Estas variables no están incluidas en el modelo, lo que puede provocar que algunos perfiles aparezcan como similares en términos ofensivos, pero difieran significativamente en su aportación global dentro del juego.

6.2 Conclusión final

A través del análisis del mediocentro organizador, se ha logrado identificar perfiles con características similares a Toni Kroos mediante técnicas de similitud basadas en distancia euclidiana, complementadas con herramientas de visualización como el PCA y los gráficos radar. Este enfoque ha permitido detectar jugadores con distintos grados de afinidad en términos de creación y progresión del juego, destacando perfiles como Angelo Stiller o Enzo Fernández como posibles candidatos, aunque con matices en su estilo de juego.

El modelo desarrollado constituye una herramienta útil para identificar perfiles similares desde una perspectiva ofensiva y de creación de juego, pero debe entenderse como un punto de partida dentro del proceso de scouting.

Para una evaluación más completa y realista, sería necesario incorporar:

- métricas defensivas
- variables tácticas
- contexto del equipo y rol del jugador

De este modo, se podría construir un modelo más robusto que capture de forma más fiel la complejidad del perfil de un mediocentro como Toni Kroos.